补充实验一：R^2 是否已经到上限？

结论：不能认定已到上限；本轮仍有小幅提升，但没有出现足以支持明显突破的结果。也没有、且无法声称穷尽所有机器学习方法。

针对"是否试过迭代和删异常值"的问题，本轮新增 63 组配置（含对照）、315 个五折验证分数，并比较 11 个 RF/SVR 加权比例。此前 588 组搜索记录继续保留。各类方案均先根据训练集 CV 确定，再对完整 273 条固定测试记录评价一次；所有成功和退化结果一并记录。

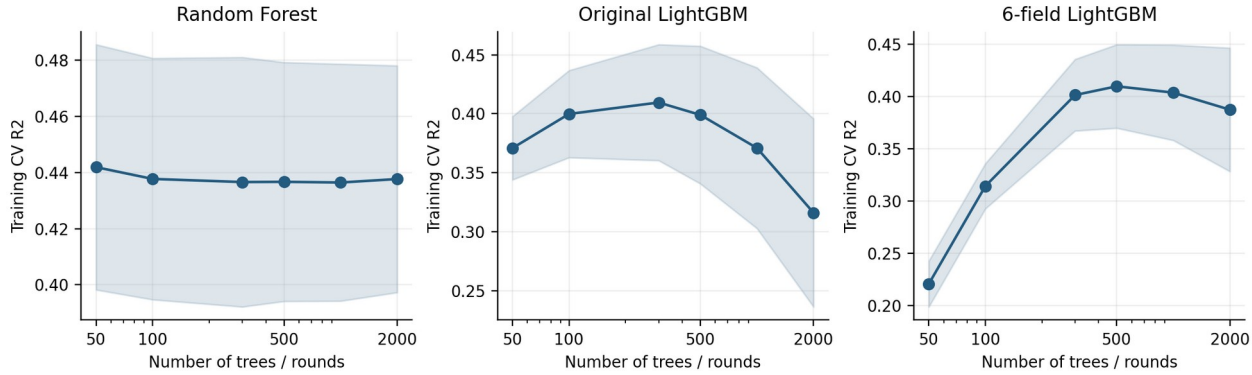
问题	已补做的检验	边界
更多树／轮次	RF 及两种 LightGBM 各 50、100、300、500、1000、2000 轮	18 组；不靠测试分数选轮次
稳健拟合	16 组 Huber 与 16 组匹配平方损失梯度提升	降低极端残差影响，不等于识别错误记录
删除异常样本	仅 X 空间 IsolationForest、训练 OOF 残差，各 1%、2%、5%	规则只在当折训练子集估计
缩尾	同样分位点截断训练目标，各 1%、2%、5%	不修改验证或测试观测值
模型互补	已选 RF 和 SVR，RF 权重 0 至 1、间隔 0.1	11 种权重，仅按训练 OOF 五折均值选择

统一条件：1363 条数据（延续原代码 Li≤2000），1090 训练／273 测试，目标 ln(1+Li)，原随机划分种子 42，五折种子 20261018。采用已有 6 个等价信息组；全部候选预测均使用固定非负下限。原代码中的 Li>2000 筛选没有在本轮重新论证。

迭代不是重复换随机种子直到分数变好。随机森林的树数、提升树的逐轮残差拟合、MLP 的数值优化迭代含义不同。此前 MLP 已扩至 5000 步并检查收敛；本轮重点检查树数曲线。

成熟实现来源：scikit-learn GitHub 仓库中的 RandomForestRegressor、GradientBoostingRegressor、IsolationForest 及 cross_val_predict；具体链接、参数、逐折分数保存在 additional_experiments/。

补充实验二：为什么更多迭代不一定更好？



图：训练 CV 均值；阴影为五折标准差，表示折间波动，不是置信区间。测试结果未用于绘制或选择曲线峰值。

训练 CV R^2	50	100	300	500	1000	2000
RF	0.4419	0.4377	0.4366	0.4366	0.4364	0.4376
原 LightGBM	0.3709	0.3998	0.4095	0.3990	0.3709	0.3161
去冗余 LightGBM	0.2206	0.3142	0.4013	0.4097	0.4036	0.3873

RF：500→2000 棵时，CV R^2 约 0.4366→0.4376，变化仅约+0.0010。更多树主要降低随机抽样带来的波动，无法补充缺失的解释变量；该随机种子下 50 棵的 CV 均值最高，但其测试 R^2 为 0.5380，低于 500 棵的 0.5403。不能据此普遍宣称少树更好。

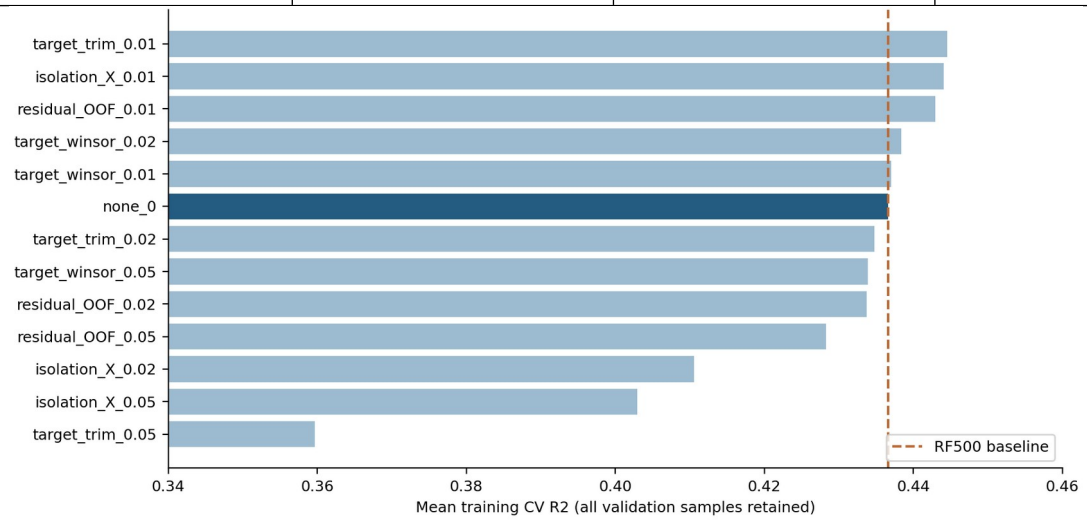
原 LightGBM：CV 在 300 轮约 0.4095，2000 轮降至 0.3160；去冗余 LightGBM 在 500 轮约 0.4097，2000 轮降至 0.3873。提升树继续拟合训练残差，也可能逐步拟合噪声。因此“尚未收敛时增加迭代”和“过拟合后继续增加迭代”应分开判断。

原 LightGBM 训练 CV 选择 300 轮，测试 R^2 为 0.5333，低于原 500 轮的 0.5396。保留这次反例；训练内验证是合理的选型依据，但不能保证某一次固定测试划分必然提高。

补充实验三：删异常值和缩尾的实际结果

以下"异常"只是统计筛选标签，目前没有经实验记录核实的数据错误。删除规则均只作用于训练子集；273 条测试记录全部保留。

按训练 CV 选中的规则	CV R^2 ±折间 SD	测试 R^2	全训练集处理量
不新增处理（RF500）	0.4366 ± 0.0425	0.5403	保留 1090
目标双尾剔除 1%	0.4445 ± 0.0271	0.5442	删 10，保留 1080
IsolationForest 1%	0.4441 ± 0.0296	0.5337	删 11
OOF 绝对残差 1%	0.4429 ± 0.0467	0.5409	删 11
目标双尾缩尾 2%	0.4384 ± 0.0370	0.5355	不删，改 20 个训练目标



图含全部 12 种处理强度及对照；none_0 为不新增处理。更激进的处理通常退化，例如目标双尾剔除 5% 的 CV R^2 降至 0.3597，不能靠多删样本稳定提高分数。

补充实验四：完整结果和新增删样本清单

候选（各类别训练 CV 选中）	CV R^2	测试 R^2	相对 RF500 Δ
RF50 训练 CV 选中	0.4419	0.5380	-0.0023
原 LightGBM：300 轮	0.4095	0.5333	-0.0070
去冗余 LightGBM：500 轮	0.4097	0.4851	-0.0552
训练目标双尾剔除 1%	0.4445	0.5442	+0.0039
训练目标双尾缩尾 2%	0.4384	0.5355	-0.0048
IsolationForest 筛除 1%	0.4441	0.5337	-0.0067
OOF 残差筛除 1%	0.4429	0.5409	+0.0005
梯度提升 Huber 损失	0.3970	0.5240	-0.0163
匹配梯度提升 平方损失	0.3918	0.5363	-0.0040
RF500 对照	0.4366	0.5403	+0.0000
RF/SVR 各 50%平均	0.4525	0.5432	+0.0029

Huber 最佳训练 CV 约 0.3970，匹配平方损失约 0.3918；对应测试分别 0.5240、0.5363，均低于 RF500。Huber 对大残差降低权重可能改善稳健性，但 R^2 使用平方误差评价，二者优化目标并不完全相同。不能保证稳健损失使 R^2 提高。

简单平均：训练 CV 从 RF 的 0.4366 升至 0.4525，折间 SD 从 0.0425 降至 0.0298；测试仅从 0.5403 升至 0.5432，MAE 从 0.5738 降至 0.5638。它没有新增删除样本，但需要训练两个模型，也使单一模型的重要性解释更复杂。

目标双尾剔除 1%的实际规则：在 1090 条训练样本的 ln(1+Li)上取 0.5%和 99.5%分位点，低于下界或高于上界才剔除（边界并列保留）。换回原浓度，下界约 0.2、上界约 655.531；因此实际删 10 条，并非强制凑 11 条。

原 QSH Excel 行号→Li：3→720；64→799；271→977；327→0；328→0；331→0；333→0；1284→660；1287→740；1288→820。其中 4 条为 0，6 条为 660–977。零值可能涉及检出限或真实低值，高值也可能具有研究意义；这些解释尚未经来源记录核实。

本轮最高观测测试 R^2=0.5442 来自上述删尾部敏感性方案。相对原 RF 实跑 0.5390 总共约+0.0052，相对前次修改 RF0.5403 约+0.0039，不能称为明显突破，更不能把它视为删错值已得到证实。

补充结论：瓶颈证据、推荐与组会表述

已核实的事实

① 23 列中有 18 列提供完全线性重复的信息，去冗余后是 6 个独立数值方向，不能将列数当作独立信息量。② 气候变量之间高度相关。③ 存在完全相同输入对应不同 Li 的记录，例如原 Excel 行 1289 与 1296，全部 23 个输入相同，Li 却为 10 和 450。④ 多类模型及本轮迭代／稳健／筛样本实验仍集中在相近的测试 R^2 附近。

上述事实支持"当前输入信息及数据质量值得优先核查"的判断，但不能证明 0.54 是数学上限。相同输入不同输出只说明这些记录无法被仅依赖当前 X 的确定性模型同时精确拟合。该冲突究竟来自未观测地质、水化学、采样层位/时间等因素，还是环境栅格分辨率、字段提取、单位或记录误差，需要进一步证据。候选缺失因素是待核实解释，当前数据无法确定其贡献。

下一步的实际优先级

优先核对 18 个重复字段的原始提取过程及单位、零值与高值的实验记录、重复环境输入对应不同 Li 的采样条件。若原始信息有误，修复后重新建模；若存在真实差异，再考虑补充有物理依据且预测时可取得的变量。收集与核实数据有时间成本，应先查可疑字段，再决定是否做更多调参。

当前建议：主分析保留不新增删样本的 RF 及已有完整结果；0.5442 删尾部模型作为敏感性分析，RF/SVR 平均作为预测补充。不要为追分数直接把它们替换成最终物理影响结论。若要给组合模型报告因子重要性，应重新对组合预测函数评价，不能直接平均两个模型的原始重要性数值。

验证限制：本测试集已在此前开发中多次查看，属于内部开发验证。本轮虽然没有用测试分数选参数，也没有删除测试点，但持续试验仍可能产生选择乐观；小幅增益需要新样本或预先固定的独立验证确认。此处未做可支持"统计显著提升"的独立检验。没有证据保证 R^2 能达到 0.7 或 0.8，也没有证据证明继续研究一定无效。

组会可直接表述："我们没有把目前 R^2 当作上限。本轮增加了迭代曲线、稳健损失、训练内异常样本处理和简单集成；完整测试集仍保留 273 条。最高观测 R^2 为 0.5442，但依赖删去训练尾部 10 条记录；不新增删样本的集成为 0.5432。增益都很小，下一阶段应优先核查重复字段及同输入不同 Li 的来源，而不是保证通过加迭代或删点实现大幅提升。"

复现：additional_experiments/frozen_data.npz 保存清洗后数组、固定划分与源 Excel 行号。安装父目录 requirements.txt 后，执行 python run_additional.py 及 python ensemble_check.py 即可重跑本轮；frozen_data 来自原 QSH 及原清洗规则，源文件哈希见主目录 source_manifest.json。全部逐折记录与删样本行号保留；models/缓存不属于交付必需文件。