变量筛选一：是否需要保留全部 23 列？

结论：不需要机械保留全部 23 列，但"重要性前 6／7 列"不等于 6 个非重复信息组。进一步删变量能否提高 R^2，需要训练内选择与完整测试对照。

当前 23 列中，18 列提供完全线性重复信息，分别是 CECS、CECT、SpH、SOC、SCF、SSiF、SSaF、SGC、TCF、TSiF、TSaF、TGC、OAR、SNRC、SNA、TpH、TOC、ST。合并后保留 CECS 作为共享代表，以及 AET、AI、Alpha(AET/PET)、PET、BIO7，共 6 个非重复组。这只是数值信息的去重复，不是确认 18 项物理作用相同，也不表示其余 5 项相互独立。

第 7 列必然来自现有信息的重复表示。它可能改变随机森林选特征时的权重和数值路径，但不提供第 7 类新的数据信息。不能把 6→7 列的偶然分数变化解释为获得新机制。

对照	列数	训练 CV R^2	测试 R^2
原 RF：23 列	23	0.4112	0.5390
修改 RF 参数：23 列	23	0.4225	0.5434
训练内重要性前 6 列：原 RF 参数	6	0.4095	0.5403
训练内重要性前 7 列：原 RF 参数	7	0.4093	0.5393
修改 RF：6 个非重复信息组	6	0.4366	0.5403

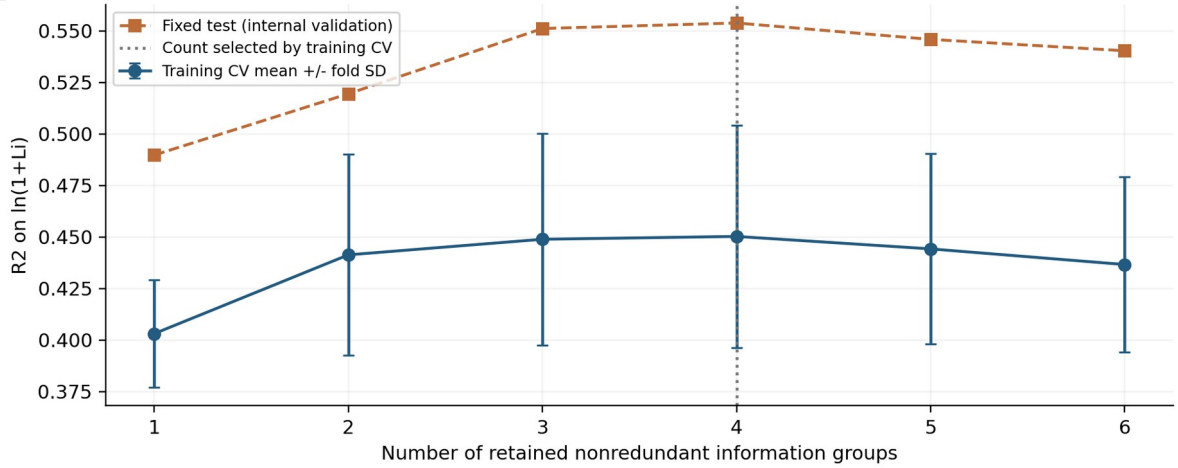
原参数对照：23 列、前 6 列、前 7 列均使用原 RF 的 1000、10、叶节点最少 3 条。修改参数对照：23 列与去重复 6 组均使用 500 棵树、深度 8、max_features=0.3、ccp_alpha=0.001。这样将变量处理与算法参数变化分开记录。

此前图中的重要性使用过测试数据，不能再直接据其挑列。本轮对每个训练折另做 80/20 内部分割：在内层训练拟合原 RF，在内层验证做 10 次置换排名；选前 6 或 7 列后，重新用整个外层训练折拟合，外层验证不参与排名。最终列名也只由 1090 条训练数据的内部划分确定。

全部训练数据内最终前 6 列：PET、AET、AI、BIO7、Alpha(AET/PET)、SOC；第 7 列为 SSiF。这些是本次数值排名，不是物理影响强弱的最终定论。

变量筛选二：保留 1–6 组的实际对照

组数	该组数下训练 CV 选中的变量	CV R^2	测试 R^2
1	AET	0.4031	0.4898
2	AET、Alpha(AET/PET)	0.4414	0.5195
3	AET、AI、Alpha(AET/PET)	0.4489	0.5511
4	AET、AI、Alpha(AET/PET)、BIO7	0.4503	0.5538
5	CECS、AET、AI、Alpha(AET/PET)、BIO7	0.4442	0.5459
6	CECS、AET、AI、Alpha(AET/PET)、PET、BIO7	0.4366	0.5403



图中每个组数只显示该组数下训练 CV 均值最高的组合；误差线为五折标准差，不是置信区间。最终模型按训练 CV 选择，不按测试曲线峰值回选。

训练 CV 总体选中：AET、AI、Alpha(AET/PET)、BIO7，共 4 组。训练 CV R^2=0.4503，测试 R^2=0.5538；相对 6 组 RF 测试 R^2=0.5403，变化+0.0135。

本轮枚举 6 组的全部 63 个非空组合，每组固定已有修改 RF 参数，不额外重调深度或树数。加上 4 个原始列对照，共 67、335 个外层验证分数；按相同五折训练 CV 选定每个组数及总体方案，再评价原 273 条测试样本。未新增删除任何训练或测试记录。

由于特征数变化，max_features=0.3 对应的候选列数也可能变化；删除重复表示还会改变某类信息被树节点抽中的机会。因此即使数值信息没有减少，RF 预测仍可能改变。

变量筛选三：解释、限制与组会建议

为什么不能简单按重要性排名删变量？

高度相关或重复的变量可以互相替代，单列置换重要性容易被分摊或压低；单看排名可能重复选中同一信息，也可能漏掉有互补作用的变量。变量在单独使用时弱，并不意味着与其他变量组合时无用。

训练外折	仅当折训练内选出的前 6 列	非重复组数
1	Al、PET、Alpha(AET/PET)、BIO7、AET、CECT	6
2	PET、AET、Al、BIO7、TSiF、SOC	5
3	PET、Al、AET、BIO7、Alpha(AET/PET)、SOC	6
4	PET、Al、AET、Alpha(AET/PET)、BIO7、SpH	6
5	AET、PET、Al、BIO7、Alpha(AET/PET)、SGC	6

同一共享组在不同折中可能由 SOC、TSiF、CECT 或 SpH 等字段占位。它们在现有表中的数值关系相同，不能据这种排序差异解释土壤物理机制。应先核对原始字段提取与单位，再决定这些字段的科学保留方式。

本轮训练 CV 选中的子集在测试上提高了 0.0135，可作为简化模型的候选；仍需独立验证其稳定性。不能只因为少列或一次分数较高就认定它代表全部控制机制。

研究目标是"不同因子对 Li 浓度的关系"，预测筛选与科学解释需要分开。某项删掉后分数不降，可能只是被相关变量替代，不代表它没有物理作用；置换重要性也不等于因果效应或可相加的贡献率。理论上关键的控制变量应结合研究依据判断，不能只按 R^2 自动删除。

验证限制：本轮训练 CV 被用于比较 63 个组合，其最优值可能乐观；没有把选中后的 CV 当作无偏泛化估计。固定测试也已在此前开发中被查看，属于内部验证。保留按训练 CV 确定的模型和所有正负结果，不根据测试最高值重新挑组。新的变量数结论仅针对 RF、本数据和固定参数，不能直接推广至 SVR、LightGBM 或 MLP。

复现与记录：feature_selection/保存 67 组训练均值、335 个逐折分数、每折内层排名训练/验证行号、最终选择记录、10 个固定测试对照及逐行预测。运行 python run_feature_selection.py 重现；使用同目录 frozen_data.npz 和 source_protocol.json，依赖与主目录一致。