多环境因子与 Li 浓度关系
四种回归模型复现与改进记录

组会汇报材料｜以原始 Python 代码与 QSH.xlsx 为准

2026 年 10 月 18 日｜连续浓度回归与因子预测重要性

核心结论：SVR 获得一定改善，RF 基本持平；MLP 的最终分数提高主要依赖物理非负下限修正；LightGBM 本轮改动在固定测试集退化。所有升降均保留，不把失败试验写成成功。

模型	原始 R^2	最终 R^2	ΔR^2	RMSE 降幅
RF	0.5390	0.5403	+0.0013	+0.15%
SVR	0.4680	0.5135	+0.0456	+4.38%
LightGBM	0.5396	0.4851	-0.0545	-5.75%
MLP	0.3562	0.5007	+0.1445	+11.93%

所有主表指标均为 ln(1+Li)尺度；同一批 273 条测试记录。ΔR^2 是绝对差值，不是"准确率提高多少个百分点"。RMSE 降幅为负表示误差变大。

- RF：0.5390→0.5403，不能称为实质提升。
- SVR：0.4680→0.5135；训练内五折均值和折间波动同时改善。
- MLP：0.3562→0.5007；其中约 0.0171 来自训练修改，约 0.1273 来自修正一条负预测，必须分开汇报。
- LightGBM：0.5396→0.4851；本次候选不建议替换原版，失败结果及原因假设均保留。

建议：以 RF 和原始 LightGBM 约 0.54 的表现作为当前参考，同时继续核对数据字段和信息覆盖。模型重要性仅表示预测依赖，不是已经证实的因果影响。

1　原始流程、数据与公平比较规则

本次研究仅围绕 Li 浓度回归展开。图名笔误不作为模型问题；结果以本轮上传 Excel 和实际代码复现为准。

环节	统一设置
输入与目标	QSH.xlsx；目标 Li；原始 23 个候选输入字段
排除字段	Li、ID、ID_1、E、W、1/0，与原代码一致
数据处理	原 clean_data_final 保持；去缺失/非数值后 1365 条；沿用 Li≤2000，排除 2 条后 1363 条
目标变换	y = np.log1p(Li)，即 ln(1+Li)，保持原代码
固定测试集	test_size=0.2、random_state=42；训练 1090、测试 273
内部验证	仅训练集内 KFold(5, shuffle=True, random_state=20261018)
参数选择	按训练内平均 R^2 选择；测试集用于检验选中方案，不用于挑参数
额外约束	固定 ŷ=max(原始预测,0)，来自 Li 浓度非负性，不从测试集学习阈值

1.1 指标定义与边界

$R^2 = 1 - \Sigma(y_i-\hat{y}_i)^2 / \Sigma(y_i-\bar{y})^2$；$RMSE = \sqrt{mean((y-\hat{y})^2)}$；$MAE = mean(|y-\hat{y}|)$。

此处 y 是 ln(1+Li)，所以 R^2、RMSE 和 MAE 不能混同于原始浓度尺度，也不能叫分类准确率。NSE 在原公式下与 R^2 完全相同，不作为第二条独立证据。

适用范围沿用原代码的 Li≤2000 筛选。保留该筛选是为了公平比较，不代表本次重新证明了剔除高值的科学依据。

1.2 复现核验

模型	上传 Excel R^2	本环境复现 R^2	说明
RF	0.538933	0.538987	差约 5.4×10^{-5}；主对比用同环境复现值
SVR	0.467979	0.467979	一致
LightGBM	0.539625	0.539625	一致
MLP	0.356201	0.356201	一致

2　修改路线与收益分解

实际顺序：原代码复现 → 固定数据和划分 → 训练内比较正则化、去冗余、归一化/PCA 与迭代模型 → 针对 SVR/LightGBM/MLP 再搜索 → 检查 MLP 收敛与数值复现 → 冻结参数 → 检验测试集 → 补充固定物理下限及因子解释核查。

共完成 588 组随机搜索配置：第一轮广泛比较 396 组，收到另外三份代码后针对性比较 192 组；每组使用同一训练五折。另有两组 MLP 求解收敛复核。候选数不等于独立算法数量。

模型	原始	原始+仅下限	训练修改后 未加下限	最终 修改+下限
RF	0.5390	0.5390	0.5403	0.5403
SVR	0.4680	0.4979	0.5135	0.5135
LightGBM	0.5396	0.5396	0.4851	0.4851
MLP	0.3562	0.3562	0.3733	0.5007

各列为固定测试集 R^2。“原始+仅下限”与“训练修改后”是不同分支，不能将两条分支的增益相加；主分解路径为原始→训练修改→固定下限。

非负下限的依据：Li≥0 意味着 ln(1+Li)≥0。若原预测小于 0，将其设为 0 不会增加任何非负实测值的平方误差或绝对误差。该约束不改变训练标签，也不删除测试记录。

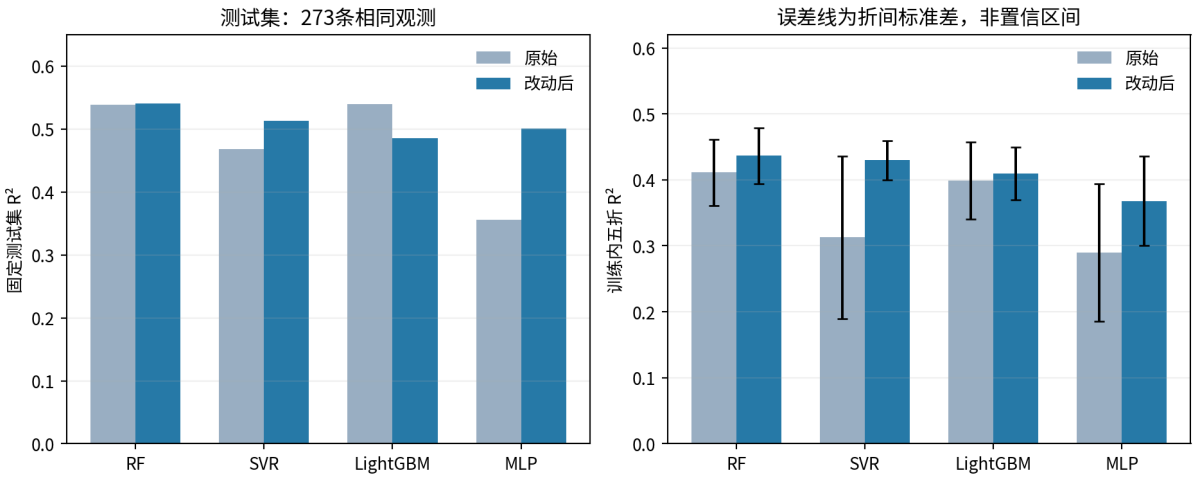


图 1　固定测试集与训练内五折验证对比。CV 误差线为折间标准差，不是置信区间。

3 Random Forest：小改与实际收益

修改项	原始	最终	目的
输入表示	23 列	合并为 6 组数值信息	去除完全线性重复表示，保留已有信息
树数量	1000	500	控制重复拟合成本，不宣称树更少导致更准
max_depth	10	8	限制模型复杂度
min_samples_leaf	3	1	在其他约束下经 CV 选择，并非所有约束都增大
max_features	1.0（默认）	0.3	增强特征抽样、降低树间相关
ccp_alpha	0.0（默认）	0.001	代价复杂度剪枝

训练 CV R^2：0.4112→0.4366；固定测试 R^2：0.5390→0.5403。训练拟合下降，测试几乎不变，说明减少过拟合倾向并不自动产生明显泛化收益。

对照试验：保留 23 列、仅调整 RF 正则化参数时，测试 R^2 为 0.5383，也没有改善。最终采用训练 CV 较高的"去重复+RF"方案，未依据测试分数另挑参数。

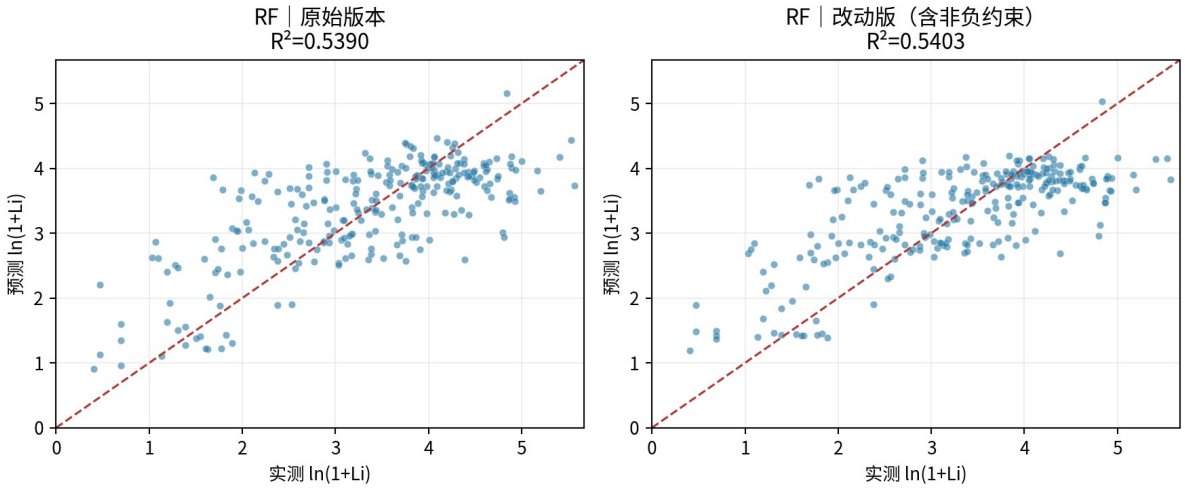


图 2　RF 修改前后；两图使用相同测试记录与坐标范围。

结论：可作为更清楚的建模与字段解释版本，但仅 $\Delta R^2 \approx +0.0013$，不宜作为显著性能突破汇报。

4　SVR：核参数与正则化调整

修改项	原始	最终
标准化	Pipeline 内 StandardScaler	保留；原代码此处已正确实现
输入表示	23 列（18 列线性重复）	6 组数值信息，避免核距离重复计权
核函数	RBF	RBF，保留
C	100	7.873647301696307
gamma	0.1	1.4490330125116613
epsilon	0.05	0.05，最终未变
预测范围	无约束	统一下限 0；最终测试预测均已非负

C 变小意味着对复杂拟合施加更强限制；gamma 控制核作用范围，epsilon 控制误差不敏感带。参数联合在训练五折内比较，不能孤立宣称某一个参数单独带来全部收益。

固定测试 R^2 由 0.4680 升至 0.5135，Δ=+0.0456；RMSE 下降 4.38%，MAE 仅下降 0.22%。平方误差改善较明显，典型绝对误差的改善较小，不能只报一个指标。

原 SVR 仅加非负下限即可达到 R^2=0.4979；完整修改版为 0.5135。最终训练内五折 R^2 约 0.4298±0.0296，原始为 0.3130±0.1233，验证波动也有所减小。

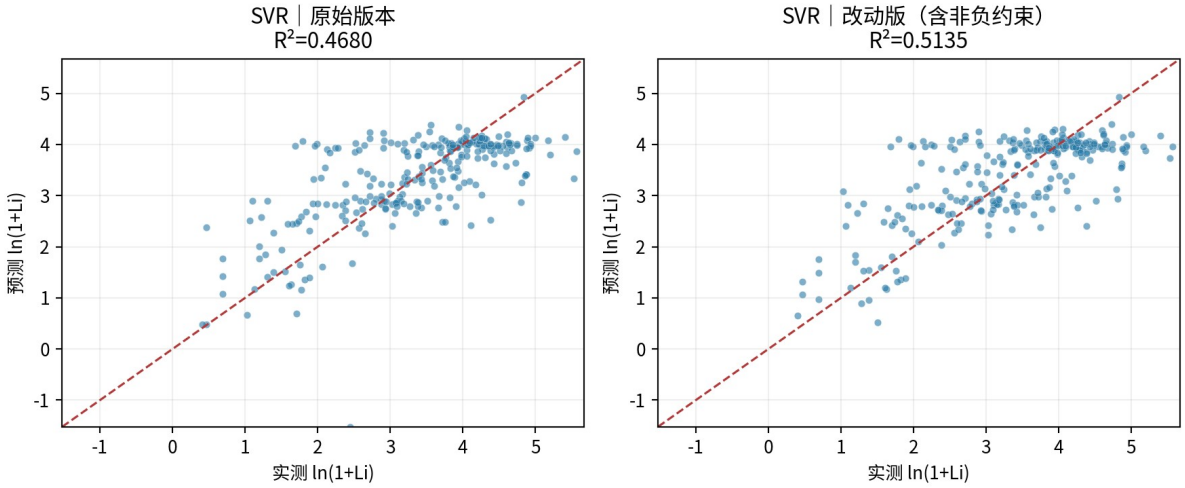


图 3　SVR 修改前后。原版存在一条负 ln 预测，仍在左图保留。

5 LightGBM：有效配置核查与退化结果

修改项	原始	最终
learning_rate / 树数	0.03 / 500	0.01 / 500
max_depth / num_leaves	5 / 20	−1 / 7（用叶子数约束复杂度）
min_child_samples	20（默认）	5
reg_lambda / reg_alpha	0 / 0（默认）	0.1 / 0
colsample_bytree	0.8	1.0
subsample / subsample_freq	0.8 / 0（默认）	1.0 / 1
重要性定义	默认 feature_importances_：分裂次数	统一为测试组置换 R^2 下降量

配置事实：原 subsample=0.8 在 subsample_freq=0 时不会启用行采样。搜索时显式设置频率 1 并比较采样比例，但最终 CV 选中 subsample=1.0，因此最终没有行采样，不能把收益归功于“开启采样”。

内部 CV 均值由 0.3990 到 0.4097，但固定测试 R^2 由 0.5396 降到 0.4851，RMSE 反而增加约 5.75%。本次修改未通过固定测试集检验，不建议替换原版。

可能解释：更强平滑可能削弱该测试集需要的非线性结构，也可能反映单次划分与调参选择的波动。现有对照不能确定唯一原因。失败候选和全部参数记录均保留。

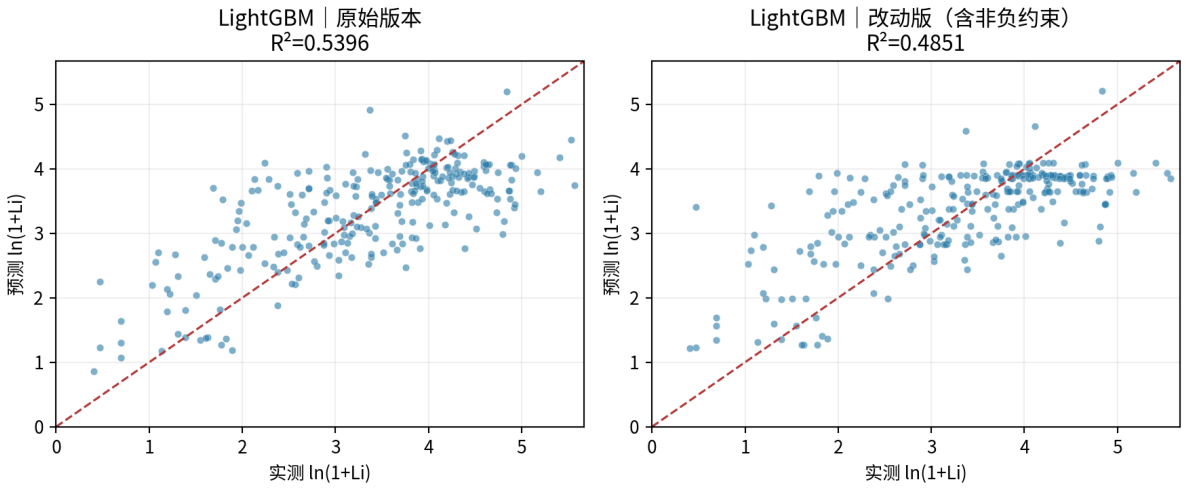


图 4　LightGBM 本轮修改出现退化，未删除或隐藏该结果。

6 MLP：结构、L2 正则与求解收敛

修改项	原始	最终
标准化	Pipeline 内 StandardScaler	保留；不是新增改进
隐藏层	(64, 32)	(16, 8)
激活函数	relu	relu（搜索比较过 tanh）
求解器	adam	lbfgs
alpha（L2 强度）	0.0001（默认）	1.2970554218079453
max_iter / max_fun	1000 / 默认	5000 / 100000
实际最终迭代数	254（Adam）	1293（L-BFGS）
最终预测	未约束	max(原始 ln 预测, 0)

原 MLP 并没有产生收敛警告，不能笼统指责原训练"没有收敛"。本次比较了较小网络、更强 L2，以及 Adam 早停和 L-BFGS 两类方案；最终选中 L-BFGS，未使用 Adam 早停。

最初上限 1000 的 L-BFGS 候选达到预算并报警；提高到 5000 后，6 组输入版本五折均无收敛警告，各折 730–3800 步，最终全训练集 1293 步。23 列候选即使提高上限仍有 4/5 折及最终拟合未收敛，未作为最终版本。

增加迭代上限并未使 CV 分数继续升高：6 组候选在上限 1000 时均值 0.3740，但有警告；收敛复核后原始 CV 约 0.3677。不能把"允许 5000 步"写成"实际训练 5000 步"或"迭代越多越好"。不同求解器的迭代定义也不能直接当作相同训练量比较。

6.1 数值复现控制

相同数值输入的布局	最终迭代数	未加下限测试 R^2
C 连续布局（最终固定）	1293	0.3733
F 连续布局（诊断，不选用）	711	0.4926

相同数值、不同内存布局产生了不同浮点计算路径，影响非凸 L-BFGS 的优化轨迹。最终明确使用 np.ascontiguousarray 固定 C 布局，并按该结果复跑，不挑偶然更高的一次。跨计算库或平台仍可能有数值差异。

6.2 不能把全部收益记到调参名下

原始 R^2=0.3562；训练修改后未加下限=0.3733；加入固定非负下限后=0.5007。总增益+0.1445 中，训练修改+0.0171，下限修正+0.1273。

7　非负约束：最小修改与单点敏感性

raw_pred = model.predict(X_test)
y_pred = np.maximum(raw_pred, 0.0)

这一行是预测后处理。它不学习测试标签，不改变任何观测，不删除异常样本。变量重要性计算使用同样的有界评分规则，避免“主分数用截断、重要性却用未截断模型”的不一致。

模型 / 分支	Excel 行号	实测 Li	原始 ln 预测	设定下限
SVR / original	1152	10.5	-1.5202	0
MLP / modified	1152	10.5	-4.4415	0

两条负预测都发生在同一条测试记录（Excel 第 1152 行，Li=10.5）。并未据此删除该记录。MLP 最终 R^2 的很大一部分改善依赖这一条预测修正：训练内 CV 因该下限的均值增益只有约 0.0003，而固定测试集增益约 0.1273，说明结果具有明显单点敏感性。

因此应说“加入物理下限避免了非法负浓度，并改善本测试集的平方误差”，不应说“神经网络已普遍获得同等幅度的泛化提升”。

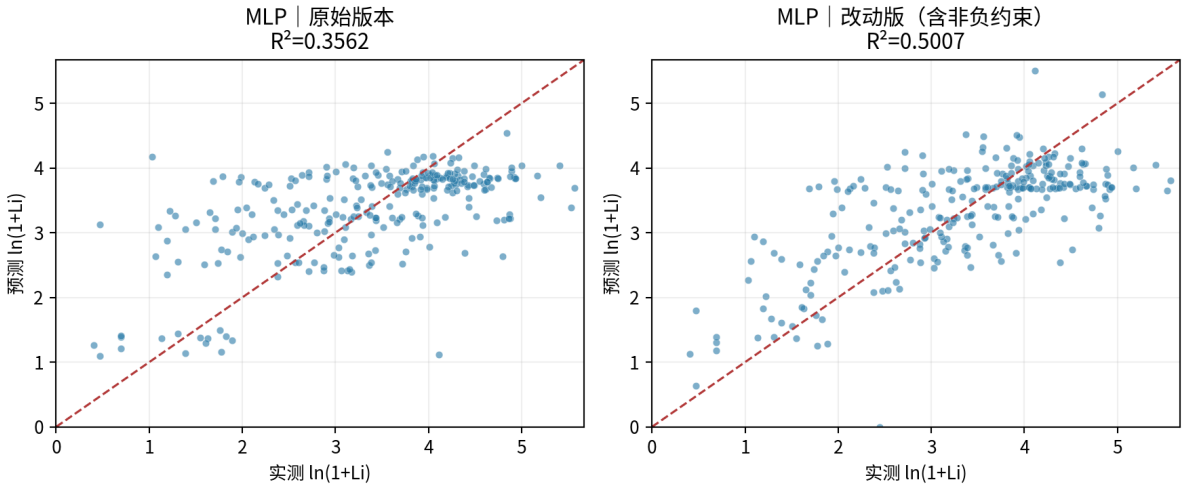


图 5　MLP 最终版本包含物理下限。未截断预测和逐项收益保存在明细表中。

8 因子影响程度：统一口径与可解释边界

原 RF、SVR、MLP 使用置换重要性，原 LightGBM 默认使用分裂次数，不能直接比较柱高或数值。本报告另计算统一的测试组置换：打乱某组输入后 R^2 下降多少，20 次随机置换，random_state=42。

18 个完全线性重复字段共同置换，保持它们的内部关系；改动版以 CECS 代表这组共享信息。其余 5 个气候字段分别评估。原版与改动版在同一批记录和相同置换序列下比较。

因子/组	RF	SVR	LightGBM	MLP
AET	0.1214	0.4630	0.5682	6.1131
AI	0.1140	0.3482	0.1516	3.1437
BIO7	0.1155	0.4580	0.0767	1.4685
PET	0.1126	0.4582	0.2971	2.8520
Alpha(AET/PET)	0.0700	0.3749	0.0161	4.5368
共享 18 字段	0.0315	0.2078	0.0182	0.5040

上述数值不是百分比，也不要求加起来等于 1。置换下降量可以大于 1，因为打乱变量后模型可能产生很差、甚至负的 R^2。MLP 的数值明显偏大，反映其对共线变量组合和外推很敏感，不表示它证明了数倍的真实物理作用。

AET、AI、Alpha 等高度相关（例如 AET 与 AI 的 r 约 0.981，AET 与 Alpha 约 0.988）。分别打乱会形成原数据中少见的组合，尤其可能放大 SVR 和 MLP 的置换损失。统一单位仍不能消除模型本身的稳定性差异。

目前可支持：这些气候字段包含预测信息，RF 的前四个单变量置换分数接近。不可支持：把某一柱高直接解释为因果效应、可相加的贡献率，或断言某一因子具有压倒性作用。

9　统一重要性图与联合块检验

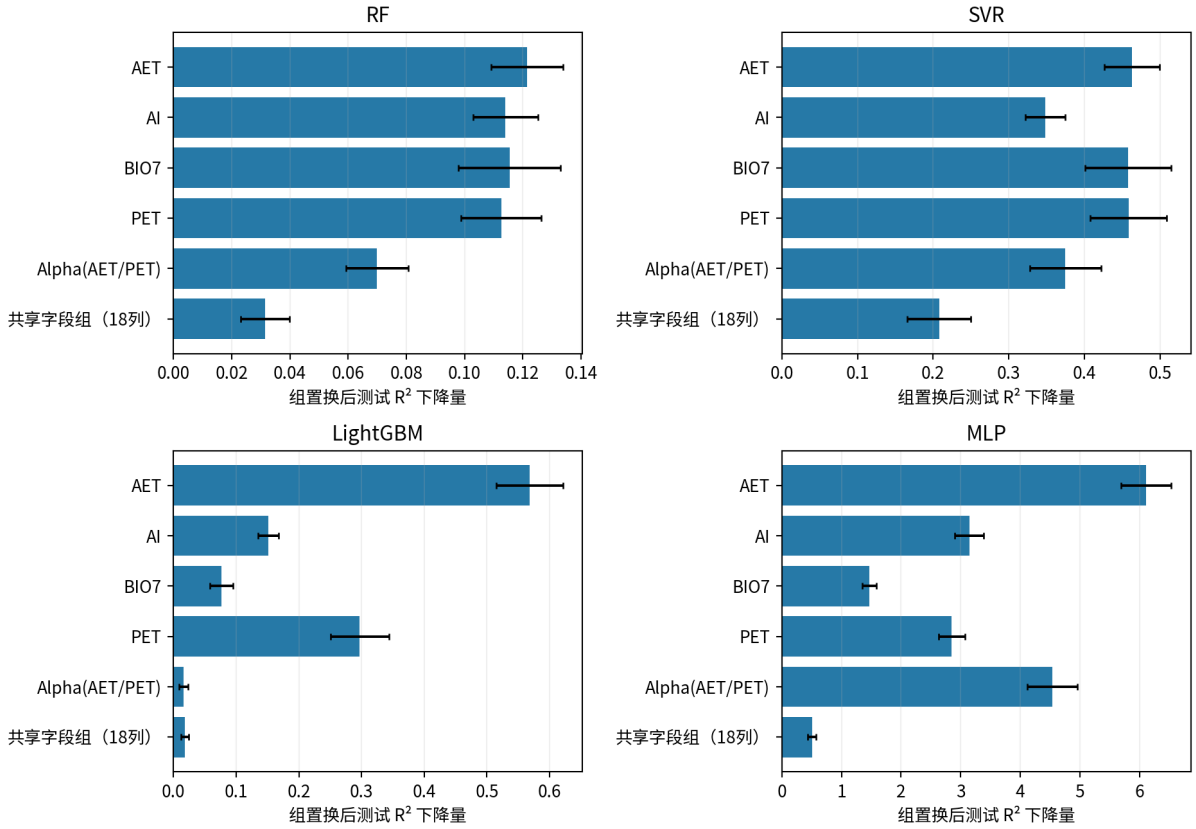


图 6　改动版的组置换重要性。四个子图横轴范围不同，需读刻度；误差线为重复置换标准差。

作为补充，将 5 个气候字段一起置换，保留它们之间原有的实际组合：

模型	5 气候字段共同置换 ΔR²	共享字段组 ΔR²
RF	0.8888	0.0315
SVR	1.0964	0.2078
LightGBM	0.8676	0.0182
MLP	1.1677	0.5040

联合块检验有助于减少气候组内关系被破坏的影响，但仍是统计预测诊断，不能替代机理实验或因果识别。

10　解释稳定性：RF 去一组因子重训练

为区分“模型依赖某字段”和“该字段提供独立增量信息”，对当前 RF 补充去一组因子再训练：每个训练验证折固定参数，移除一组，重新拟合，比较相同验证记录的 R^2。正数表示移除后变差；负数表示移除后反而略好。

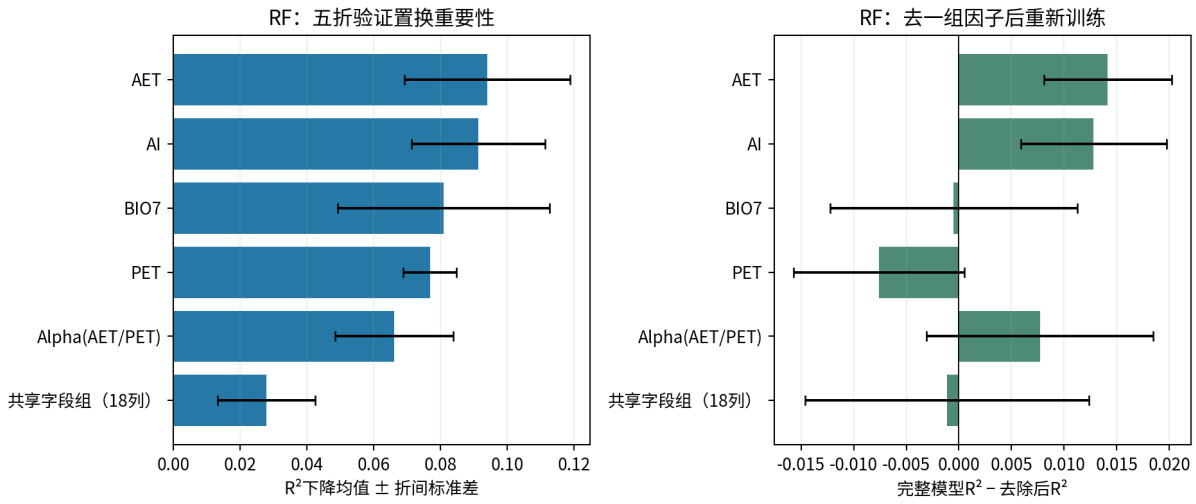


图 7　左：跨折置换依赖；右：去一组因子后重训练的增量预测价值。两者回答不同问题。

因子/组	均值 ΔR²	折间标准差	五折范围
AET	+0.0142	0.0061	[+0.0055, +0.0216]
AI	+0.0128	0.0069	[+0.0076, +0.0227]
Alpha(AET/PET)	+0.0077	0.0108	[-0.0050, +0.0204]
BIO7	-0.0005	0.0118	[-0.0109, +0.0184]
共享 18 字段	-0.0011	0.0135	[-0.0170, +0.0147]
PET	-0.0076	0.0081	[-0.0187, +0.0028]

AET 与 AI 在此固定 RF 设置下保留了小幅、相对稳定的增量预测信息。PET 移除后均值反而略高，并不证明 PET 无物理作用：其他共线变量可以替代它，也可能存在建模与抽样波动。此检验未为每种删列重新调参，结论仅针对当前建模设置。

11　数据限制、汇报措辞与后续工作

11.1 已核实的数据事实

- 原 23 列中，CECS、CECT、SpH、SOC、SCF、SSiF、SSaF、SGC、TCF、TSiF、TSaF、TGC、TpH、TOC、ST 逐行相同；OAR、SNRC 为其 2 倍，SNA 为 3 倍。因此只能辨认共享信息，不能独立估计这 18 个物理因子的作用。
- 存在 188 条额外记录落在相同输入组合中；例如一组两条记录 23 个输入完全相同，但 Li 分别为 10 和 450。任何只依赖这些输入的确定性模型都会给它们同样预测。
- 这一反例说明部分误差无法仅靠换算法消除，并不证明 R^2 约 0.54 就是总体可达上限。字段提取问题、未观测因素、采样条件差异或测量噪声仍需原始记录核实。

11.2 当前结果的边界

主结果来自一次固定随机留出，是内部开发验证，未进行外部独立数据验证；CV 最大值还存在多重选参的乐观倾向。小差异不称为显著提升。RF 与原 LightGBM 均约 0.54，不能仅因末位差异就判定稳健优劣。

优先核对重复字段对应的真实属性、样本匹配和高杠杆测试记录；若需提高因素辨识度，应补充有实质新信息、能区分同环境不同浓度样本的变量。当前没有足够依据把重要性排名当作主控机理结论。

11.3 组会口头汇报简稿

“本次以四份原始回归代码为基准，保留相同样本筛选、对数变换和训练测试划分，先复现原结果，再在训练集内做五折参数比较。修改重点是去除完全重复表示、针对不同算法调整正则化与复杂度，并核对求解收敛和浓度非负约束。

结果并不是所有方法都提高。RF 基本不变；SVR 的测试 R^2 从 0.468 提高到 0.514，内部验证也更稳定；LightGBM 本次候选退化，保留为负面结果。MLP 最终到 0.501，但调参只贡献约 0.017，主要增益来自纠正一条负预测，因此不能全部归因于网络结构优化。

解释方面，统一了原先不同定义的变量重要性，并补充跨折和去一组因子重训。当前数据中 18 个字段共享同一组数值，气候变量也高度相关，所以能报告预测关联与信息冗余，暂不能精确分离每个环境因子的真实因果作用。下一步先核实数据，再判断是否需要更复杂模型。”

附录 A　实验清单与未胜出方案

第一轮方案	训练五折 R^2	折间标准差
RF_deduplicated	0.4366	0.0425
RF_regularized	0.4271	0.0369
ExtraTrees	0.4188	0.0460
HistGradientBoosting	0.4177	0.0457
SVR_scaled	0.4126	0.0270
GradientBoosting	0.4074	0.0488
CatBoost	0.4054	0.0677
LightGBM	0.4054	0.0404
KNN_scaled	0.4013	0.0392
RF_PCA_scaled	0.3953	0.0269
KernelRidge_scaled	0.3698	0.0954
ElasticNet_scaled	0.2165	0.0580

上表为 396 组搜索中各方案的训练 CV 最优值，并非它们的测试集排名；未逐一查看这些方案测试分数后挑冠军。CatBoost、LightGBM 等使用成熟开源实现，最终交付脚本仍保留用户原有四算法。

新增针对性方案	配置数	训练 CV 最优 R^2
SVR_full23	36	0.4028
LightGBM_full23	36	0.4097
MLP_full23	24	0.3184
SVR_dedup	36	0.4298
LightGBM_dedup	36	0.4097
MLP_dedup	24	0.3740

MLP 表中 1000 步 L-BFGS 最优候选存在收敛警告，后续分别用 5000 步预算复核，不将其不稳定分数直接当最终模型成绩。

附录 B　搜索空间、控制变量与失败记录

方案	主要搜索维度
RF / 去重复 RF	深度{4,6,8,10,14,None}；叶子样本{1,3,5,10,20}；特征比例{0.3,0.6,1.0}；样本比例{0.6,0.8,None}；ccp_alpha{0,0.001,0.01}；每方案 36 组、500 棵树
SVR（针对性）	C：log-uniform(0.1,1000)；gamma：log-uniform(0.001,3)；epsilon∈{0.01,0.05,0.1,0.2,0.3}；23 列/6 组各 36 组
LightGBM（针对性）	树数{300,500,900}；步长{0.01,0.03,0.05}；深度{3,5,8,-1}；叶子{7,15,20,31}；min_child_samples{5,10,20,40}；L1{0,0.1,1,10}；L2{0,0.1,1,10,100}；采样{0.6,0.8,1}；min_split_gain{0,0.01,0.1}；每表示 36 组
MLP（针对性）	层结构{(8),(16),(32),(16,8),(32,16)}；激活 relu/tanh；L2 alpha：log-uniform(0.001,100)；Adam 分支使用训练内早停（15%，30 步耐心、2000 上限）与学习率搜索；L-BFGS 分支 1000 上限。23 列/6 组各 24 组
求解复核	两种 MLP 输入表示均增加到 max_iter=5000，max_fun=100000；不使用测试集作早停集
归一化/PCA 等	仅训练折拟合标准化/PCA；完整 588，，，与拟合耗时

失败与纠正的记录

- 保留 23 列、只调 RF 正则化：测试 R^2 约 0.5383，未改善；不回避该结果。
- LightGBM：内部 CV 小幅变好而固定测试退化，不能只报 CV 的提高。
- MLP：1000 步预算未收敛→提高预算并逐折检查；23 列分支仍不收敛而未选用。
- 交付复跑发现 MLP 与实验不一致→定位为 C/F 内存布局改变求解路径→固定 C 布局复跑，未挑更高的一次。
- 原 SVR 与 MLP 候选出现负 In 预测→保留原始预测、加入预先固定的物理下限→单独列出后处理收益与负预测记录。

附录 C　复现、文件导航与开源依据

推荐环境：Python3.12.14、NumPy2.3.5、pandas2.2.3、scikit-learn1.8.0、matplotlib3.10.8、openpyxl3.1.5、LightGBM4.7.0。CatBoost1.2.10 仅用于广泛方法比较。MLP 结果对数值库与求解路径敏感；环境信息需和结果一起留存。

```
python -m pip install -r requirements.txt
python code/RF_modified.py QSH.xlsx --output results/RF
python code/SVR_modified.py QSH.xlsx --output results/SVR
python code/LightGBM_modified.py QSH.xlsx --output results/LightGBM
python code/MLP_modified.py QSH.xlsx --output results/MLP
```

LightGBM 树图另需要 Graphviz 系统程序 dot。训练与结果计算不依赖树图的机理解释。中文字体影响图中文字显示，不改变数值计算。

文件/目录	用途
Li_group_meeting_report.docx / PDF	本报告：用于组会阅读与复核
group_meeting_results.xlsx	原始复现、最终测试、消融、预测、统一重要性、跨折稳定性与数据实例
all_training_search_records.csv	588 组训练搜索配置与每折结果
code/ + originals/ + diffs/	四份修改版、原代码副本与逐行差异
results/ + figures/	各脚本实跑输出及组会前后对比图
negative_prediction_ablation.csv	负预测位置与原始/有界输出，便于排除夸大收益
four_selected_frozen.json + final_cv_folds.json	冻结的参数与逐折验证记录
source_manifest.json	输入文件大小与 SHA256，确认使用的数据版本

开源方案与方法参考

https://github.com/scikit-learn/scikit-learn

https://github.com/scikit-learn/scikit-learn/blob/main/examples/inspection/plot_permutation_importance_multicollinear.py

https://github.com/scikit-learn/scikit-learn/blob/main/examples/neural_networks/plot_mlp_alpha.py

https://github.com/microsoft/LightGBM

https://github.com/catboost/catboost

输入数据 SHA256：

0c9430d5148ddf187b5508b44c2adb4af82ad6e8ffdd4c814578d9647d8f40b5

所有表格和图来自本次实际运行。未将未运行方案写成已验证；未把收敛警告写成通过；未把变量重要性写成因果贡献。

补充实验一：R^2 是否已经到上限？

结论：不能认定已到上限；本轮仍有小幅提升，但没有出现足以支持明显突破的结果。也没有、且无法声称穷尽所有机器学习方法。

针对"是否试过迭代和删异常值"的问题，本轮新增 63 组配置（含对照）、315 个五折验证分数，并比较 11 个 RF/SVR 加权比例。此前 588 组搜索记录继续保留。各类方案均先根据训练集 CV 确定，再对完整 273 条固定测试记录评价一次；所有成功和退化结果一并记录。

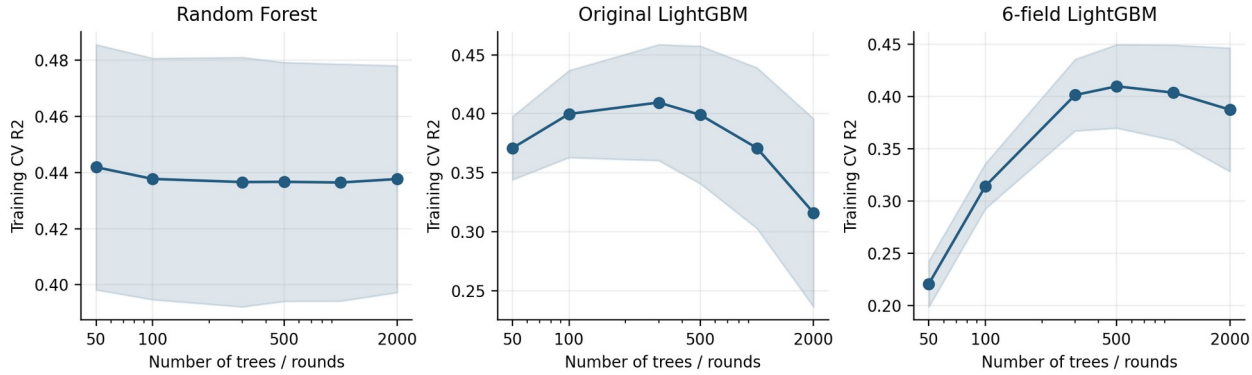
问题	已补做的检验	边界
更多树／轮次	RF 及两种 LightGBM 各 50、100、300、500、1000、2000 轮	18 组；不靠测试分数选轮次
稳健拟合	16 组 Huber 与 16 组匹配平方损失梯度提升	降低极端残差影响，不等于识别错误记录
删除异常样本	目标分位数、X 空间 IsolationForest、训练 OOF 残差，各 1%、2%、5%	规则只在当折训练子集估计
缩尾	同样分位点截断训练目标，各 1%、2%、5%	不修改验证或测试观测值
模型互补	已选 RF 和 SVR，RF 权重 0 至 1、间隔 0.1	11 种权重，仅按训练 OOF 五折均值选择

统一条件：1363 条数据（延续原代码 Li≤2000），1090 训练／273 测试，目标 ln(1+Li)，原随机划分种子 42，五折种子 20261018。采用已有 6 个等价信息组；全部候选预测均使用固定非负下限。原代码中的 Li>2000 筛选没有在本轮重新论证。

迭代不是重复随机搜索，而是在固定折上逐步增加树数，检查每一步的验证分数变化。随机森林看的是增加树后的袋外残差，提升树看的是每一轮后的验证集残差。重点检查树数曲线。

成熟实现来源：scikit-learn GitHub 仓库中的 RandomForestRegressor、GradientBoostingRegressor、IsolationForest 及 cross_val_predict；具体链接、参数、逐折分数保存在 additional_experiments/。

补充实验二：为什么更多迭代不一定更好？



图：训练 CV 均值；阴影为五折标准差，表示折间波动，不是置信区间。测试结果未用于绘制或选择曲线峰值。

训练 CV R^2	**50**	**100**	**300**	**500**	**1000**	**2000**
RF	0.4419	0.4377	0.4366	0.4366	0.4364	0.4376
原 LightGBM	0.3709	0.3998	0.4095	0.3990	0.3709	0.3161
去冗余 LightGBM	0.2206	0.3142	0.4013	0.4097	0.4036	0.3873

RF：500→2000 棵时，CV R^2 约 0.4366→0.4376，变化仅约+0.0010。更多树主要降低随机抽样带来的波动，无法补充缺失的解释变量；该随机种子下 50 棵的 CV 均值最高，但其测试 R^2 为 0.5380，低于 500 棵的 0.5403。不能据此普遍宣称少树更好。

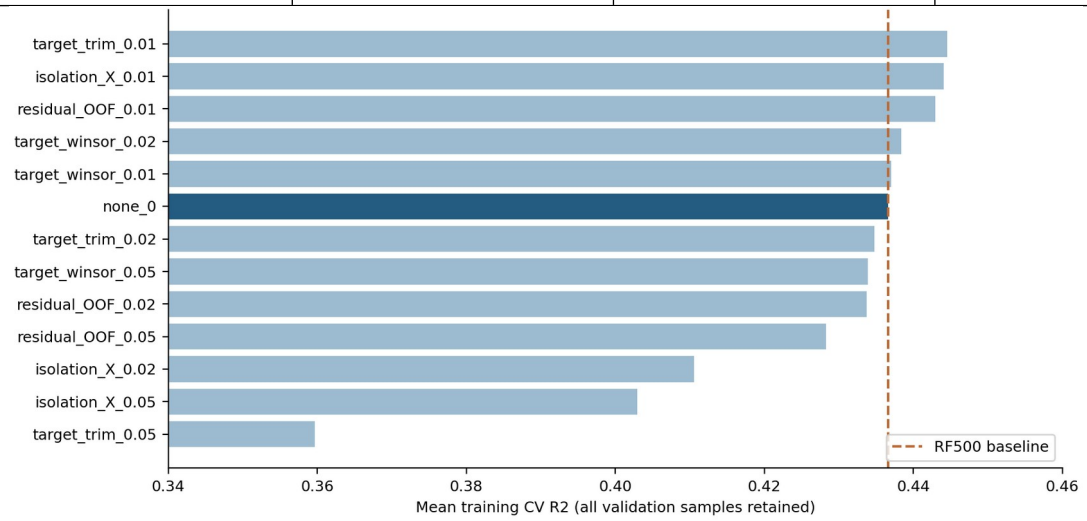
原 LightGBM：CV 在 300 轮约 0.4095，2000 轮降至 0.3160；去冗余 LightGBM 在 500 轮约 0.4097，2000 轮降至 0.3873。提升树继续拟合训练残差，也可能逐步拟合噪声。因此“尚未收敛时增加迭代”和“过拟合后继续增加迭代”应分开判断。

原 LightGBM 训练 CV 选择 300 轮，测试 R^2 为 0.5333，低于原 500 轮的 0.5396。保留这次反例；训练内验证是合理的选型依据，但不能保证某一次固定测试划分必然提高。

补充实验三：删异常值和缩尾的实际结果

以下"异常"只是统计筛选标签，目前没有经实验记录核实的数据错误。删除规则均只作用于训练子集；273 条测试记录全部保留。

按训练 CV 选中的规则	CV R^2 ±折间 SD	测试 R^2	全训练集处理量
不新增处理（RF500）	0.4366 ± 0.0425	0.5403	保留 1090
目标双尾剔除 1%	0.4445 ± 0.0271	0.5442	删 10，保留 1080
IsolationForest 1%	0.4441 ± 0.0296	0.5337	删 11
OOF 绝对残差 1%	0.4429 ± 0.0467	0.5409	删 11
目标双尾缩尾 2%	0.4384 ± 0.0370	0.5355	不删，改 20 个训练目标



图含全部 12 种处理强度及对照；none_0 为不新增处理。更激进的处理通常退化，例如目标双尾剔除 5% 的 CV R^2 降至 0.3597，不能靠多删样本稳定提高分数。

补充实验四：完整结果和新增删样本清单

候选（各类别训练 CV 选中）	CV R^2	测试 R^2	相对 RF500 Δ
RF50 训练 CV 选中	0.4419	0.5380	-0.0023
原 LightGBM：300 轮	0.4095	0.5333	-0.0070
去冗余 LightGBM：500 轮	0.4097	0.4851	-0.0552
训练目标双尾剔除 1%	0.4445	0.5442	+0.0039
训练目标双尾缩尾 2%	0.4384	0.5355	-0.0048
IsolationForest 筛除 1%	0.4441	0.5337	-0.0067
OOF 残差筛除 1%	0.4429	0.5409	+0.0005
梯度提升 Huber 损失	0.3970	0.5240	-0.0163
匹配梯度提升 平方损失	0.3918	0.5363	-0.0040
RF500 对照	0.4366	0.5403	+0.0000
RF/SVR 各 50%平均	0.4525	0.5432	+0.0029

Huber 最佳训练 CV 约 0.3970，匹配平方损失约 0.3918；对应测试分别 0.5240、0.5363，均低于 RF500。Huber 对大残差降低权重可能改善稳健性，但 R^2 使用平方误差评价，二者优化目标并不完全相同。不能保证稳健损失使 R^2 提高。

简单平均：训练 CV 从 RF 的 0.4366 升至 0.4525，折间 SD 从 0.0425 降至 0.0298；测试仅从 0.5403 升至 0.5432，MAE 从 0.5738 降至 0.5638。它没有新增删除样本，但需要训练两个模型，也使单一模型的重要性解释更复杂。

目标双尾剔除 1%的实际规则：在 1090 条训练样本的 ln(1+Li)上取 0.5%和 99.5%分位点，低于下界或高于上界才剔除（边界并列保留）。换回原浓度，下界约 0.2、上界约 655.531；因此实际删 10 条，并非强制凑 11 条。

原 QSH Excel 行号→Li：3→720；64→799；271→977；327→0；328→0；331→0；333→0；1284→660；1287→740；1288→820。其中 4 条为 0，6 条为 660–977。零值可能涉及检出限或真实低值，高值也可能具有研究意义；这些解释尚未经来源记录核实。

本轮最高观测测试 R^2=0.5442 来自上述删尾部敏感性方案。相对原 RF 实跑 0.5390 总共约+0.0052，相对前次修改 RF0.5403 约+0.0039，不能称为明显突破，更不能把它视为删错值已得到证实。

补充结论：瓶颈证据、推荐与组会表述

已核实的事实

① 23 列中有 18 列提供完全线性重复的信息，去冗余后是 6 个独立数值方向，不能将列数当作独立信息量。② 气候变量之间高度相关。③ 存在完全相同输入对应不同 Li 的记录，例如原 Excel 行 1289 与 1296，全部 23 个输入相同，Li 却为 10 和 450。④ 多类模型及本轮迭代／稳健／筛样本实验仍集中在相近的测试 R^2 附近。

上述事实支持"当前输入信息及数据质量值得优先核查"的判断，但不能证明 0.54 是数学上限。相同输入不同输出只说明这些记录无法被仅依赖当前 X 的确定性模型同时精确拟合。该冲突究竟来自未观测地质、水化学、采样层位/时间等因素，还是环境栅格分辨率、字段提取、单位或记录误差，需要进一步证据。候选缺失因素是待核实解释，当前数据无法确定其贡献。

下一步的实际优先级

优先核对 18 个重复字段的原始提取过程及单位、零值与高值的实验记录、重复环境输入对应不同 Li 的采样条件。若原始信息有误，修复后重新建模；若存在真实差异，再考虑补充有物理依据且预测时可取得的变量。收集与核实数据有时间成本，应先查可疑字段，再决定是否做更多调参。

当前建议：主分析保留不新增删样本的 RF 及已有完整结果；0.5442 删尾部模型作为敏感性分析，RF/SVR 平均作为预测补充。不要为追分数直接把它们替换成最终物理影响结论。若要给组合模型报告因子重要性，应重新对组合预测函数评价，不能直接平均两个模型的原始重要性数值。

验证限制：本测试集已在此前开发中多次查看，属于内部开发验证。本轮虽然没有用测试分数选参数，也没有删除测试点，但持续试验仍可能产生选择乐观；小幅增益需要新样本或预先固定的独立验证确认。此处未做可支持"统计显著提升"的独立检验。没有证据保证 R^2 能达到 0.7 或 0.8，也没有证据证明继续研究一定无效。

组会可直接表述："我们没有把目前 R^2 当作上限。本轮增加了迭代曲线、稳健损失、训练内异常样本处理和简单集成；完整测试集仍保留 273 条。最高观测 R^2 为 0.5442，但依赖删去训练尾部 10 条记录；不新增删样本的集成为 0.5432。增益都很小，下一阶段应优先核查重复字段及同输入不同 Li 的来源，而不是保证通过加迭代或删点实现大幅提升。"

复现：additional_experiments/frozen_data.npz 保存清洗后数组、固定划分与源 Excel 行号。安装父目录 requirements.txt 后，执行 python run_additional.py 及 python ensemble_check.py 即可重跑本轮；frozen_data 来自原 QSH 及原清洗规则，源文件哈希见主目录 source_manifest.json。全部逐折记录与删样本行号保留；models/缓存不属于交付必需文件。

变量筛选一：是否需要保留全部 23 列？

结论：不需要机械保留全部 23 列，但"重要性前 6／7 列"不等于 6 个非重复信息组。进一步删变量能否提高 R^2，需要训练内选择与完整测试对照。

当前 23 列中，18 列提供完全线性重复信息，分别是 CECS、CECT、SpH、SOC、SCF、SSiF、SSaF、SGC、TCF、TSiF、TSaF、TGC、OAR、SNRC、SNA、TpH、TOC、ST。合并后保留 CECS 作为共享代表，以及 AET、AI、Alpha(AET/PET)、PET、BIO7，共 6 个非重复组。这只是数值信息的去重复，不是确认 18 项物理作用相同，也不表示其余 5 项相互独立。

第 7 列必然来自现有信息的重复表示。它可能改变随机森林选特征时的权重和数值路径，但不提供第 7 类新的数据信息。不能把 6→7 列的偶然分数变化解释为获得新机制。

对照	列数	训练 CV R^2	测试 R^2
原 RF：23 列	23	0.4112	0.5390
修改 RF 参数：23 列	23	0.4225	0.5434
训练内重要性前 6 列：原 RF 参数	6	0.4095	0.5403
训练内重要性前 7 列：原 RF 参数	7	0.4093	0.5393
修改 RF：6 个非重复信息组	6	0.4366	0.5403

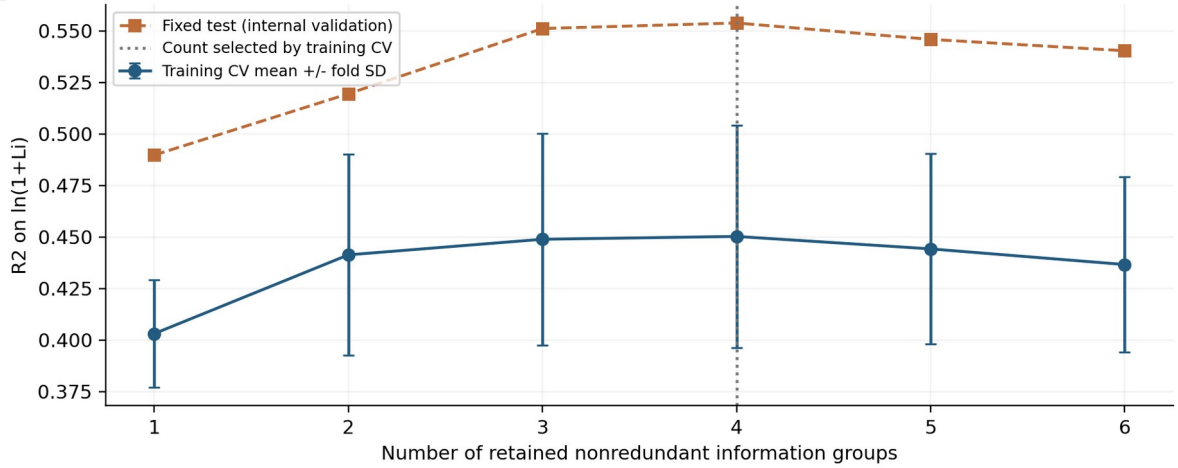
原参数对照：23 列、前 6 列、前 7 列均使用原 RF 的 1000 棵树、深度 10、叶节点最少 3 条。修改参数对照：23 列与去重复 6 组均使用 500 棵树、深度 8、max_features=0.3、ccp_alpha=0.001。这样将变量处理与算法参数变化分开记录。

此前图中的重要性使用过测试数据，不能再直接据其挑列。本轮对每个训练折另做 80/20 内部分割：在内层训练拟合原 RF，在内层验证做 10 次置换排名；选前 6 或 7 列后，重新用整个外层训练折拟合，外层验证不参与排名。最终列名也只由 1090 条训练数据的内部划分确定。

全部训练数据内最终前 6 列：PET、AET、AI、BIO7、Alpha(AET/PET)、SOC；第 7 列为 SSiF。这些是本次数值排名，不是物理影响强弱的最终定论。

变量筛选二：保留 1–6 组的实际对照

组数	该组数下训练 CV 选中的变量	CV R^2	测试 R^2
1	AET	0.4031	0.4898
2	AET、Alpha(AET/PET)	0.4414	0.5195
3	AET、AI、Alpha(AET/PET)	0.4489	0.5511
4	AET、AI、Alpha(AET/PET)、BIO7	0.4503	0.5538
5	CECS、AET、AI、Alpha(AET/PET)、BIO7	0.4442	0.5459
6	CECS、AET、AI、Alpha(AET/PET)、PET、BIO7	0.4366	0.5403



图中每个组数只显示该组数下训练 CV 均值最高的组合；误差线为五折标准差，不是置信区间。最终模型按训练 CV 选择，不按测试曲线峰值回选。

训练 CV 总体选中：AET、AI、Alpha(AET/PET)、BIO7，共 4 组。训练 CV R^2=0.4503，测试 R^2=0.5538；相对 6 组 RF 测试 R^2=0.5403，变化+0.0135。

本轮枚举 6 组的全部 63 个非空组合，每组固定已有修改 RF 参数，不额外重调深度或树数。加上 4 个原始列对照，共 67 种方案、335 个外层验证分数；按相同五折训练 CV 选定每个组数及总体方案，再评价原 273 条测试样本。未新增删除任何训练或测试记录。

由于特征数变化，max_features=0.3 对应的候选列数也可能变化；删除重复表示还会改变某类信息被树节点抽中的机会。因此即使数值信息没有减少，RF 预测仍可能改变。

变量筛选三：解释、限制与组会建议

为什么不能简单按重要性排名删变量？

高度相关或重复的变量可以互相替代，单列置换重要性容易被分摊或压低；单看排名可能重复选中同一信息，也可能漏掉有互补作用的变量。变量在单独使用时弱，并不意味着与其他变量组合时无用。

训练外折	仅当折训练内选出的前 6 列	非重复组数
1	Al、PET、Alpha(AET/PET)、BIO7、AET、CECT	6
2	PET、AET、Al、BIO7、TSiF、SOC	5
3	PET、Al、AET、BIO7、Alpha(AET/PET)、SOC	6
4	PET、Al、AET、Alpha(AET/PET)、BIO7、SpH	6
5	AET、PET、Al、BIO7、Alpha(AET/PET)、SGC	6

同一共享组在不同折中可能由 SOC、TSiF、CECT 或 SpH 等字段占位。它们在现有表中的数值关系相同，不能据这种排序差异解释土壤物理机制。应先核对原始字段提取与单位，再决定这些字段的科学保留方式。

本轮训练 CV 选中的子集在测试上提高了 0.0135，可作为简化模型的候选；仍需独立验证其稳定性。不能只因为少列或一次分数较高就认定它代表全部控制机制。

研究目标是"不同因子对 Li 浓度的关系"，预测筛选与科学解释需要分开。某项删掉后分数不降，可能只是被相关变量替代，不代表它没有物理作用；置换重要性也不等于因果效应或可相加的贡献率。理论上关键的控制变量应结合研究依据判断，不能只按 R^2 自动删除。

验证限制：本轮训练 CV 被用于比较 63 个组合，其最优值可能乐观；没有把选中后的 CV 当作无偏泛化估计。固定测试也已在此前开发中被查看，属于内部验证。保留按训练 CV 确定的模型和所有正负结果，不根据测试最高值重新挑组。新的变量数结论仅针对 RF、本数据和固定参数，不能直接推广至 SVR、LightGBM 或 MLP。

复现与记录：feature_selection/保存 67 组训练均值、335 个逐折分数、每折内层排名训练/验证行号、最终选择记录、10 个固定测试对照及逐行预测。运行 python run_feature_selection.py 重现；使用同目录 frozen_data.npz 和 source_protocol.json，依赖与主目录一致。